

PROJET RAKUTEN

Classification multimodale de produits e-commerce

Rendu 1 - Exploration, Dataviz et Preprocessing

Auteurs :

Khoty WOLIE | [Prénom NOM 2] | [Prénom NOM 3]

Formation Ingénieur IA - Liora

Avril 2026



1. Introduction au projet

1.1 Contexte

Rakuten est une entreprise japonaise fondée en 1997, considérée comme l'une des plus grandes plateformes de commerce en ligne au monde, avec plus de 1,3 milliard de membres. En France, Rakuten opère une marketplace sur laquelle des vendeurs professionnels et particuliers proposent des produits neufs et d'occasion dans de très nombreuses catégories.

Le catalogage automatique des produits est un enjeu central pour ce type de plateforme. Lorsqu'un vendeur met en ligne un article, il fournit un titre, parfois une description, et une photo. Classer correctement ce produit dans la bonne catégorie est indispensable pour permettre aux acheteurs de le trouver via la recherche, pour générer des recommandations pertinentes, et pour éviter les doublons dans le catalogue. Aujourd'hui, ce processus repose en partie sur des règles manuelles ou des heuristiques simples qui ne passent pas à l'échelle face aux millions de produits référencés.

Ce projet s'inscrit dans le challenge Rakuten France Multimodal Product Data Classification, proposé sur la plateforme ENS Data Challenge. Il consiste à entraîner un modèle capable de prédire automatiquement le code de catégorie d'un produit à partir de ses données textuelles (titre et description) et de son image.

1.2 Objectifs

L'objectif principal est de construire un classifieur multimodal capable d'affecter chaque produit à l'un des 27 codes de type de produit (prdtypecode) définis dans le catalogue Rakuten France. La performance est mesurée par le weighted F1-score, qui est la métrique officielle du challenge.

Les objectifs intermédiaires de ce premier rendu sont les suivants :

- Explorer la structure et le contenu du jeu de données.
- Identifier les caractéristiques, difficultés et biais des données.
- Produire des visualisations pertinentes commentées avec une analyse métier.
- Mettre en place le pipeline de preprocessing textuel et image prête pour la modélisation.

1.3 Périmètre des données

Les données sont issues du challenge Rakuten et ne sont pas librement accessibles au public. Elles sont mises à disposition par Rakuten France dans un cadre strictement académique. Le jeu d'entraînement contient 84 916 produits avec leurs désignations, descriptions (partielles), images et labels de classe. Un jeu de test de 13 812 produits est réservé à l'évaluation finale du modèle.

2. Exploration et analyse des données

2.1 Structure du jeu de données

Le dataset d'entraînement est constitué de deux fichiers CSV fusionnés en un seul DataFrame de travail. Il contient 84 916 lignes et 5 colonnes après fusion.

Colonne	Type	Description
designation	texte	Titre court du produit. Toujours renseigné (0 valeur manquante).
description	texte	Description longue du produit. Manquante pour 35% des produits.
productid	entier	Identifiant unique du produit. Permet de construire le nom du fichier image.
imageid	entier	Identifiant unique de l'image associée au produit.
prdtypecode	entier	Variable cible : code de catégorie du produit. 27 valeurs distinctes.

La vérification de la correspondance des index entre `X_train` et `y_train` est parfaite : les 84 916 entrées sont alignées sans décalage. Aucune ligne dupliquée n'est présente sur l'ensemble des colonnes, et aucun `productid` n'est en double, ce qui confirme l'unicité de chaque fiche produit.

2.2 Valeurs manquantes

Seule la colonne `description` présente des valeurs manquantes, à hauteur de 29 800 produits, soit 35,1% du dataset. Toutes les autres colonnes sont complètes.

Ce taux de manquants est élevé et non aléatoire : certains vendeurs ne renseignent pas de `description`, et cette absence est structurellement corrélée à la catégorie du produit, comme le montre l'analyse par classe présentée en section 2.5.

2.3 Désignations dupliquées


Sur les 84 916 produits, 4 073 partagent une désignation identique avec au moins un autre produit. Parmi les 1 422 désignations uniques concernées, 1 277 pointent systématiquement vers la même classe, ce qui correspond à des produits similaires proposés par des vendeurs différents. En revanche, 145 désignations identiques sont associées à des classes différentes.

3. Analyse de la variable cible

3.1 Distribution des 27 classes

La variable cible `prdtypecode` prend 27 valeurs entières distinctes, qui correspondent aux codes de catégorie du catalogue Rakuten France. Ces codes ne sont pas consécutifs et ne suivent pas d'ordre particulier.

Le dataset présente un déséquilibre modéré entre les classes. La classe la plus représentée (code 2583) contient 10 209 produits, soit environ 12% du dataset. La classe la moins représentée (code 1180) n'en contient que 764, soit moins de 1%. Le ratio entre la classe maximale et la classe minimale est de 13,4.



Six classes sont sous le seuil de 1 000 produits : 1180 (764), 1301 (807), 1940 (803), 2220 (824), 2905 (872) et 60 (832). Ces classes minoritaires devront faire l'objet d'une attention particulière lors de l'évaluation du modèle, notamment via l'analyse des scores par classe dans la matrice de confusion.

3.2 Choix de la métrique

Le déséquilibre entre les classes justifie l'utilisation du weighted F1-score comme métrique principale. Cette métrique calcule le F1-score de chaque classe individuellement, puis en fait la moyenne pondérée par le nombre de produits de chaque classe. Elle est ainsi à la fois sensible aux erreurs sur les classes majoritaires (qui pèsent davantage dans le calcul) et informative sur les classes minoritaires.


Cette métrique est également celle retenue par le challenge officiel Rakuten, avec un benchmark texte de 0,8113 et un benchmark image de 0,5534. L'objectif du projet est de dépasser ces références, idéalement par une combinaison des deux modalités.

4. Analyse des données textuelles

4.1 Longueur des textes

Les désignations sont courtes et homogènes, avec une longueur médiane de 11 mots et un maximum de 56 mots. L'écart-type est faible (6,2), ce qui indique une distribution resserrée autour de la médiane. Les désignations constituent une feature textuelle dense et fiable.

Les descriptions, lorsqu'elles sont renseignées, sont beaucoup plus longues et hétérogènes. La longueur médiane est de 95 mots, mais l'écart-type atteint 123 et le maximum dépasse 2 000 mots. La distribution est fortement asymétrique à droite : la majorité des descriptions tient sous 200 mots, mais une queue longue existe.



Ces observations ont deux implications directes pour la modélisation. D'une part, la colonne `text_combined` (désignation + description nettoyées) sera tronquée à une longueur maximale lors du passage dans les modèles à taille d'entrée fixe (512 tokens pour les transformers). D'autre part, les descriptions manquantes seront remplacées par une chaîne vide avant la concaténation, afin de conserver une colonne texte unifiée sans perte de lignes.


4.2 Multilinguisme

La détection de langue appliquée sur les 84 916 désignations révèle que le dataset est majoritairement francophone, mais loin d'être monolingue.


Code	Langue	Nb produits
fr	Français	51 725
en	Anglais	19 670
de	Allemand	5 027
nl	Néerlandais	2 163
it	Italien	1 125
es	Espagnol	524
pt	Portugais	518
autres	Roumain, Norvégien, autres*	~4 100

* Les codes ca (catalan), af (afrikaans), tl (tagalog) sont probablement des faux positifs de détection sur des désignations courtes contenant des noms propres ou des références produit.

Top 10 des langues détectées dans les désignations



Part de désignations en français par classe




L'analyse par classe révèle un multilinguisme différencié. Trois classes affichent moins de 50% de désignations en français : la classe 1140 (environ 20% de français), la classe 40 (30%) et la classe 1160 (38%). À l'opposé, les classes 60, 2585 et 2705 dépassent 75% de français.

Cette hétérogénéité linguistique inter-classes a une implication directe sur le choix du modèle de traitement du texte. Un modèle NLP monolingue français serait inefficace sur les classes 1140, 40 et 1160, qui contiennent une majorité de textes en anglais ou en allemand. Un modèle multilingue est donc indispensable pour couvrir l'ensemble des classes sans biais linguistique.

4.3 Taux de description renseignée par classe

Le taux de description varie de manière extrême selon la classe, allant de 2,6% (classe 2403) à 100% (classe 2905). Cette variabilité est structurelle et non aléatoire.

Cinq classes disposent de moins de 10% de descriptions : 2403 (2,6%), 2462 (3,7%), 2280 (6,7%), 1160 (8,8%) et 10 (10,8%). Pour ces classes, la classification devra s'appuyer presque exclusivement sur la désignation et l'image. À l'inverse, dix classes dépassent 90% de descriptions renseignées, pour lesquelles la concaténation désignation + description apportera un signal textuel enrichi.



Ce constat confirme qu'il n'est pas pertinent d'imputer les descriptions manquantes par une valeur synthétique. Leur absence est corrélée à la classe du produit : la remplacer par une valeur artificielle introduirait un biais. La stratégie retenue est le remplacement par une chaîne vide, ce qui préserve le signal sans altérer la distribution des données.

5. Exploration des images

5.1 Couverture et disponibilité

La couverture image est totale : les 84 916 images sont disponibles sur le disque, sans aucune image manquante. C'est une différence fondamentale avec la description textuelle, qui est absente pour 35% des produits. L'image est donc la seule feature disponible à 100% pour l'ensemble du dataset.

5.2 Caractéristiques techniques des images

Une analyse des dimensions et des modes couleur sur un échantillon de 500 images représentatives révèle que toutes les images sont uniformément de taille 500 x 500 pixels et encodées en mode RGB. Il n'existe aucune variabilité de dimensions ni de mode couleur dans le dataset.

Cette uniformité est une propriété remarquable qui simplifie considérablement le pipeline de traitement. Voici quelques précisions sur les termes techniques utilisés.

Mode RGB (Red, Green, Blue).


Le RGB est le format de représentation des couleurs le plus courant pour les images numériques. Chaque pixel est décrit par trois valeurs numériques, une pour chaque canal de couleur : rouge, vert et bleu. Ces trois canaux combinés permettent de représenter toutes les couleurs visibles. Les modèles de deep learning pour la vision par ordinateur s'attendent à des images en RGB, c'est pourquoi la conversion en RGB est une étape systématique du preprocessing.

Niveaux de gris et CMJN.

Les niveaux de gris (ou grayscale) désignent des images encodées sur un seul canal, sans information de couleur, uniquement des nuances de gris du noir au blanc. Le CMJN (Cyan, Magenta, Jaune, Noir) est un format utilisé en impression professionnelle. Ces deux formats sont incompatibles avec les modèles de vision par ordinateur standard qui attendent des images RGB à 3 canaux. Dans notre dataset, aucune image n'est dans ces formats, ce qui confirme que le corpus est parfaitement homogène.

Exemples d'images par classe

Classe 10
Games For Your Dragon...



Classe 40
Xevious (Famicom Mini) Import Japon...



Classe 50
8bitdo Sn30 Gp Bluetooth Controller Game...



Classe 60
Coolbaby Ldkgame 2.6 Pouces Écran Mini C...



Classe 1140
Figurine Hasbro 2015 Star Wars Black Ser...



Classe 1160
Foil Premium Arbitre De Tertrecime - Mag...



Classe 1180
Figurine Conan Le Barbare : Jeu De Plate...



Classe 1280
Peluche Donutina 20cm Tokidoki...



Classe 1281
Super Qui Est-Ce ?...



L'affichage d'exemples d'images par classe confirme une forte séparabilité visuelle entre les catégories. Les classes correspondant aux manettes de jeu vidéo (40, 50, 60) partagent une apparence similaire d'objet noir sur fond blanc, ce qui peut créer des confusions entre ces classes proches. Les classes livres et BD (10) présentent des couvertures colorées et variées. Les figurines (1140), les cartes à jouer (1160, 1280) et les jouets (1281) sont visuellement très distincts des autres catégories.

Ces observations suggèrent que le modèle image sera performant pour distinguer des catégories visuellement éloignées, mais pourra rencontrer des difficultés sur des classes proches, notamment les accessoires de jeu vidéo, pour lesquelles le texte apportera un signal différenciateur complémentaire.

6. Preprocessing

6.1 Preprocessing textuel

Le pipeline de nettoyage textuel est appliqué de manière identique aux colonnes designation et description. Les étapes sont les suivantes, dans l'ordre d'application.

- Suppression des entités HTML

Certaines désignations et descriptions contiennent des entités HTML héritées du scraping web, par exemple ´ pour le é ou & pour le &. Ces séquences sont supprimées et remplacées par un espace.

- Suppression des balises HTML

Des balises HTML résiduelles de type
, <p> ou peuvent être présentes dans les descriptions. Elles sont supprimées.

- Normalisation unicode

La normalisation NFKD décompose les caractères accentués en leur forme de base suivie d'un modificateur. Cela permet de traiter uniformément des textes provenant de sources d'encodage différentes.

- Suppression des caractères non-alphabétiques

Les chiffres, symboles, tirets et ponctuations sont remplacés par des espaces. Seuls les caractères alphabétiques latins et accentués sont conservés.

- Normalisation des espaces et mise en minuscules

Les espaces multiples sont réduits à un seul espace, et tout le texte est converti en minuscules pour uniformiser le vocabulaire.

Après nettoyage, les descriptions manquantes sont remplacées par une chaîne vide. La colonne text_combined est ensuite construite par concaténation de designation_clean et description_clean, séparées par un espace. Le résultat est zéro texte vide sur l'ensemble des 84 916 produits, avec une longueur moyenne de 97,1 mots par texte combiné.

Il est important de noter que les étapes de suppression des stopwords, de stemming et de lemmatisation ne sont pas appliquées à ce stade. Ces traitements sont adaptés aux approches bag-of-words (TF-IDF, CountVectorizer) où les mots sont traités individuellement. Pour les modèles d'embeddings multilingues basés sur les transformers, qui seront utilisés dans la phase de modélisation, ces étapes sont inutiles voire contre-productives car elles retirent du contexte sémantique utile.

6.2 Preprocessing image

Les images du dataset sont uniformément de taille 500 x 500 pixels en RGB. Le pipeline de preprocessing image appliqué est le suivant.

- Conversion en RGB.

La conversion systématique en RGB garantit la cohérence du format, même si toutes les images sont déjà dans ce mode.

- Redimensionnement à 224 x 224 pixels.


Les modèles de transfer learning standards comme ResNet50, VGG16 ou EfficientNet ont été conçus et pré-entraînés pour recevoir des images de taille 224 x 224 pixels. Il est donc nécessaire de redimensionner toutes les images à cette taille avant de les passer dans le réseau.

L'interpolation LANCZOS utilisée pour ce redimensionnement est une méthode de rééchantillonnage de haute qualité. Redimensionner une image revient à calculer de nouveaux pixels qui n'existaient pas dans l'image originale ou à supprimer des pixels existants. LANCZOS est une méthode mathématique qui minimise les artefacts visuels (flou, pixellisation) lors de cette opération, contrairement à des méthodes plus simples comme la bilinéaire. C'est la méthode recommandée pour préparer des images destinées à des modèles de deep learning.

- Normalisation dans [0, 1].

Les valeurs des pixels d'une image brute sont des entiers entre 0 et 255 (un par canal RGB). La division par 255 ramène ces valeurs dans l'intervalle [0, 1], ce qui est la convention attendue par la plupart des frameworks de deep learning. La normalisation ImageNet (soustraction de la moyenne et division par l'écart-type par canal) sera appliquée dans le pipeline de modélisation.

Le test de validation confirme le bon fonctionnement du pipeline : l'image de sortie a une forme (224, 224, 3), des valeurs comprises entre 0 et 1, et un type float64.



7. Synthèse et orientations pour la modélisation

7.1 Récapitulatif des constats

Dimension	Constat	Implication pour la modélisation
Volume	84 916 produits, 27 classes	Dataset suffisant pour le deep learning supervisé
Déséquilibre	Ratio max/min : 13,4 (classe 2583 vs 1180)	Weighted F1-score comme métrique principale
Description	35% de NaN, hétérogène par classe	Remplacement NaN par chaîne vide, concaténation avec désignation
Multilinguisme	61% fr, 23% en, 6% de, 10 autres langues	Modèle multilingue indispensable (multilingual-MiniLM)
Images	100% disponibles, 500x500 px RGB uniformes	Pipeline image standardisé, resize 224x224, normalisation [0,1]
Ambiguïté texte	145 désignations identiques, classes différentes	L'image est nécessaire pour lever certaines ambiguïtés
Classes multilingues	Classes 1140, 40, 1160 sous 50% de français	Modèle monolingue français insuffisant

7.2 Stratégie de modélisation

Sur la base des constats établis dans ce premier rendu, la stratégie de modélisation pour le Rendu 2 s'articule en trois étapes progressives.

Étape 1 - Baseline classique.

Un modèle TF-IDF appliqué sur la colonne text_combined, combiné à une régression logistique ou un LinearSVC, servira de référence interne. L'objectif est d'établir un score de départ avant d'introduire le deep learning, et de vérifier que la colonne text_combined est exploitable telle quelle.

Étape 2 - Deep learning texte.

Un modèle d'embeddings multilingue de type sentence-transformers (paraphrase-multilingual-MiniLM-L12-v2) sera utilisé pour encoder les textes en vecteurs denses de dimension 384. Ces embeddings seront soit extraits puis classifiés par une couche dense, soit produits par fine-tuning du modèle complet. Ce modèle couvre nativement le français, l'anglais, l'allemand et de nombreuses autres langues présentes dans le dataset.

Étape 3 - Deep learning image.

Un modèle ResNet50 pré-entraîné sur ImageNet sera adapté par transfer learning pour la classification des 27 classes. Le choix de ResNet50 est aligné sur le benchmark officiel Rakuten, ce qui permettra une comparaison directe des scores. Les dernières couches seront dégelées progressivement pour un fine-tuning ciblé.

Étape 4 - Fusion multimodale.

Les embeddings texte et image produits aux étapes précédentes seront concaténés en un vecteur unique, sur lequel une couche de classification finale sera entraînée. Cette approche de fusion tardive (late fusion) est la plus simple à mettre en oeuvre et constitue une base solide avant d'explorer des architectures de fusion plus avancées.

Annexes

A. Fichiers produits

Fichier	Description
data/raw/X_train_update.csv	Données d'entraînement brutes (84 916 lignes)
data/raw/Y_train_CVw08PX.csv	Labels d'entraînement (84 916 lignes)
data/processed/df_train_processed.csv	Dataset nettoyé et enrichi, prêt pour la modélisation
reports/figures/	7 figures exportées depuis le notebook 01
notebooks/01_eda_preprocessing.ipynb	Notebook Jupyter correspondant à ce rapport

B. Colonnes du dataset exporté

Colonne	Contenu
designation	Texte original du titre produit
description	Texte original de la description (NaN si absente)
designation_clean	Titre nettoyé, en minuscules, sans HTML ni caractères spéciaux
description_clean	Description nettoyée (chaîne vide si NaN)
text_combined	Concaténation designation_clean + description_clean
productid	Identifiant unique du produit
imageid	Identifiant unique de l'image
image_path	Chemin complet vers le fichier image sur le disque
lang	Langue détectée de la désignation (code ISO 2 lettres)
prdtypecode	Variable cible : code de catégorie Rakuten